


La solution : Comptable-SLM

RAG + SLM fine-tuné — 100% droit algérien



[RAG] Pipeline RAG [SLM] Modèle local

Question → RAG (loi SCF, code fiscal...)

→ Contexte + Question → LLM

→ Réponse précise avec sources

► Embeddings : Nemotron-B Embedder (NIMB)

TF-IDF word-level accent-insensitive | Réponses sourcées | Fallback intelligent

► Vector store : ChromaDB (cosine persistent) - QLoRA (4-bit)

► 7 fichiers KB → 534 chunks (section 150 ex) algériens (SCF)

► TOP_K=4, seuil < 0.6 ► Export : GGUF → Ollama (offline)

► Contexte injecté dans le prompt → 0.03